Nowcasting Brasil

Pedro G. Costa Ferreira

Daiane Marcolino de Mattos

FGV IBRE

FGV IBRE

Guilherme Branco Gomes

Tiago dos Guaranys Martins

FGV EPGE

FGV EPGE

Resumo

Inserir resumo aqui

Palavras-chave: nowcasting, PIB, dynamic factors model.

1 Introdução

Decisões de política monetária e investimento são tomadas com base nas condições presentes e futuras da economia mesmo quando as variáveis usadas para descrever esse estado não estão acessíveis. falar da defasagem do PIB do Brasil. Por conta disso, a previsão em tempo real, ou simplesmente nowcasting, se torna um tema de relevância.

Os métodos de previsão em tempo real, que se desenvolveram nas últimas décadas, são baseados em modelos de fatores dinâmicos (DFM) e dependem de algum poder computacional para lidar com uma grande quantidade de dados. Veja Stock & Watson (2006) para uma revisão a respeito dessa literatura.

O termo nowcasting é cunhado em Giannone et al. (2008) e definido como a previsão do presente, do passado recente ou do futuro próximo. Neste artigo, os autores mostram como reduzir em apenas dois fatores dinâmicos a informação contida em dezenas de séries temporais mensais com o intuito de explicar o PIB (dos Estados Unidos) de curto prazo dos trimestres cuja informação ainda não está disponível. Após esse estudo, muitos outros continuaram explorando o uso de DFM na previsão em tempo real, como por exemplo Bańbura & Rünstler (2011) e Banbura et al. (2011). No primeiro os autores fazem uma análise mostrando como a divulgação de certas variáveis influenciam na atualização da previsão do PIB. Além disso, os autores também propõem uma medida mensal para a variável trimestral, uma vez que os fatores extraídos são mensais. No segundo, os autores propõem estimar o modelo via outro método (Expectation Maximization) e não mais por dois estágios como se fazia em Giannone et al. (2008).

O objetivo do artigo é encontrar um modelo de previsão para o PIB do Brasil segundo as propostas desenvolvidas nos artigos do parágrafo anterior. Para disseminar o uso da metodologia e reproduzir esse

Somos gratos a Domenico Giannone por disponibilizar os códigos em Matlab, assim como comentários relevantes sobre a bibliografia.

trabalho, desenvolveu-se o pacote nowcasting no R com tais métodos e algumas outras ferramentas que facilitam o tratamento de séries temporais para tal uso e que permitem analisar a importância de cada variável numa previsão. As funções de estimação foram apenas traduzidas para a linguagem, uma vez que Giannone et al. (2008) e Banbura et al. (2011) forneceram os códigos em Matlab.

A estrutura do artigo é a seguinte: na seção 2 são apresentados o arcabouço teórico sobre modelos de fatores dinâmicos, os métodos de estimação e a base de dados; na seção 3 tem-se os resultados da aplicação metodológica, a análise dos resultados e previsão extendida para o PIB do Brasil no ano de 2018. Por fim, na seção 4, têm-se as considerações finais. Embora todo o contexto apresentado aqui seja referente ao PIB, a metodologia pode ser aplicada a outras séries temporais.

2 Metodologia

2.1 Modelo de Fatores Dinâmicos

Seja $x_t = (x_{1,t}, x_{2,t}, ..., x_{N,t})'$ o vetor que representa as N séries temporais mensais transformadas para satisfazerem a suposição de estacionariedade. A especificação geral do modelo de fator dinâmico (DFM em inglês) é dada por:

$$x_t = \mu + \Lambda f_t + \varepsilon_t \tag{1}$$

$$f_t = \sum_{i=1}^{p} A_i f_{t-i} + B u_t, \quad u_t \sim NID(0, I_q)$$
 (2)

em que μ é o vetor de médias incondicionais, f_t é o vetor de fatores comuns (não observados) de dimensão $r \times 1$ modelados por um processo VAR(p) em que as matrizes A_i de dimensão $r \times r$ representam os coeficientes do processo autorregressivo e B de dimensão $r \times q$, Λ é uma matriz de constantes de dimensão $N \times r$ e ε_t é um vetor de componentes idiossincráticos, tal que $\Psi = E[\varepsilon_t \varepsilon_t']$. Assume-se ainda que $E[\varepsilon_t u'_{t-k}] = 0$ para qualquer k.

No chamado modelo de fatores dinâmicos exato assume-se que os componentes de erro são mutualmente não correlacionados em todos os lags, isto é, $E[\varepsilon_{i,t}\varepsilon_{j,s}] = 0$ para $i \neq j$. No entanto, é possível que a componente idiossincrática siga um processo AR(p) tal como se mostra na equação (3). Tal procedimento é encontrado com mais detalhes em Banbura et al. (2011).

$$\varepsilon_{i,t} = \sum_{i=1}^{p} \alpha_i \varepsilon_{i,t-i} + e_{i,t}, \quad e_{i,t} \sim NID(0, \sigma_i^2)$$
(3)

em que $E[e_{i,t}e_{j,s}] = 0$ para $i \neq j$.

Veja um exemplo da representação matricial da equação 2 do modelo apresentado considerando as

ordens r = 2, p = 2 e q = 2.

$$\begin{bmatrix} f_{1,t} \\ f_{2,t} \\ f_{1,t-1} \\ f_{2,t-1} \end{bmatrix} = \begin{bmatrix} a_{1,1}^1 & a_{1,2}^1 & a_{1,1}^2 & a_{1,2}^2 \\ a_{2,1}^1 & a_{2,2}^1 & a_{2,1}^2 & a_{2,2}^2 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} f_{1,t-1} \\ f_{2,t-1} \\ f_{1,t-2} \\ f_{2,t-2} \end{bmatrix} + \begin{bmatrix} b_{1,1} & b_{1,2} \\ b_{2,1} & b_{2,2} \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} u_{1,t} \\ u_{2,t} \end{bmatrix} \tag{4}$$

$$F_t = \begin{bmatrix} A_1 & A_2 \\ I_2 & 0 \end{bmatrix} F_{t-1} + Bu_t \tag{5}$$

2.2 Variáveis trimestrais e mensais

Para que a modelagem apresentada suporte frequências mensais e trimestrais, é utilizada a transformação proposta em Mariano & Murasawa (2003). Assim é possível que variáveis trimestrais como PIB sejam explicadas por outras variáveis de frequências mensais (fatores) ao se obter representações trimestrais para a variável mensal.

Seja Y_t^M o nível de uma variável mensal que representa o fluxo. A representação trimestral dessa variável Y_t^Q é dada por:

$$Y_t^Q = Y_t^M + Y_{t-1}^M + Y_{t-2}^M, \quad t = 3, 6, 9, \dots$$
 (6)

Defina $y_t = Y_t^M - Y_{t-1}^M$ e $y_t^Q = Y_t^Q - Y_{t-3}^Q$. Desse modo pode-se escrever y_t^Q em função de y_t de acordo com o seguinte filtro:

$$y_t^Q = y_t + 2y_{t-1} + 3y_{t-2} + 2y_{t-3} + y_{t-4}, \quad t = 3, 6, 9, \dots$$
 (7)

Assim é possível transformar diferenças mensais em diferenças trimestrais. Além disso, se a variável de interesse for uma taxa de variação, tal filtro é uma possível aproximação:

$$log(y_t^Q) \approx log(y_t) + 2log(y_{t-1}) + 3log(y_{t-2}) + 2log(y_{t-3}) + log(y_{t-4})$$
(8)

2.3 Estimação

Serão descritas duas metodologias para estimação de fatores dinâmicos: $Two\ Stages$ e Expectation & Maximization. No primeiro método considera-se que as variáveis explicativas em x_t sejam de mesma periodicidade (mensal) e a variável resposta de periodicidade trimestral. No segundo método, x_t e y_t são de periodicidade mensal.

Two Stages: Essa abordagem é apresentada no trabalho seminal de Giannone et al. (2008).
 Considerando o modelo de fatores dinâmicos exato, a estimação dos fatores dinâmicos é feita em duas etapas.

No primeiro estágio, utilizando um painel (\bar{X}_t) balanceado e padronizado, são estimados os parâmetros das matrizes Λ e f_t via PCA (Principal Components Analysis). Por balanceado entende-se as variáveis em x_t sem missings e outliers. A padronização é importante pois a

estimação via PCA não é invariante a escala. Os estimadores $\hat{\Lambda}$ e \hat{f}_t podem ser obtidos resolvendo o problema de otimização em (9).

$$\min_{f_1,\dots,f_T,\Lambda} \frac{1}{NT} \sum_{t=1}^T (\bar{X}_t - \Lambda f_t)' (\bar{X}_t - \Lambda f_t) \quad s.t. \quad N^{-1} \Lambda' \Lambda = I_r$$
(9)

Em seguida, o estimador da matriz de variância e covariância de ε_t é dado por

$$\hat{\Psi} = diag \left(\frac{1}{T} \sum_{t=1}^{T} (\bar{X}_t - \hat{\Lambda}\hat{f}_t)(\bar{X}_t - \hat{\Lambda}\hat{f}_t)' \right)$$
(10)

De acordo com Stock & Watson (2011), a solução de (9) é tal que $\hat{\Lambda}$ são os autovetores da matriz de variância e covariância de \bar{X}_t associados aos r maiores autovalores e \hat{f}_t são as r primeiras componentes principais de \bar{X}_t . Os coeficientes das matrizes A_i , i=1,2,...,p são estimados por OLS ao regredir f_t em $f_{t-1},...,f_{t-p}$. Por fim BB' é estimado como sendo a matriz de covariância dos resíduos dessa regressão.

No segundo estágio, utiliza-se Kalman smoothing para reestimar os fatores para o painel não balanceado x_t considerando os parâmetros obtidos na etapa anterior.

Nesse contexto, duas opções podem ser consideradas ao estimar os fatores:

- quarterly factors: as variáveis explicativas mensais podem ser transformadas para representarem quantidades trimestrais seguindo o procedimento visto na seção ??. Portanto, os fatores embora mensais também representarão quantidades trimestrais e, consequentemente, poderão ser transformados em variáveis de periodicidade trimestral, e assim a equação (11) pode ser estimada para a previsão da variável resposta.
- monthly factors: outra opção é estimar os fatores sobre as variáveis originais e ao final aplicar a transformação vista na seção ?? aos fatores para que representem quantidades trimestrais. Em seguida cria-se a variável de periodicidade trimestral que será usada para a previsão da variável resposta em (11).

$$y_t = \beta_0 + \beta' \hat{f}_t + e_t \tag{11}$$

Os parâmetros da equação (11) são estimados por OLS e a previsão de y_{t+h} é obtida como

$$\hat{y}_{t+h} = \hat{\beta}_0 + \hat{\beta}' \hat{f}_{t+h} \tag{12}$$

2. Expectation & Maximization: Banbura et al. (2011) apresentam novidades metodológicas, tanto na especificação do modelo quanto na estimação.

Primeiramente são impostas restrições com relação aos fatores. Os fatores são divididos em três

grupos: global, real e nominal, de modo que a equação (1) pode ser reescrita como:

$$x_{t} = \mu + \begin{pmatrix} \Lambda_{N,G} & \Lambda_{N,N} & 0\\ \Lambda_{R,G} & 0 & \Lambda_{R,R} \end{pmatrix} \begin{pmatrix} f_{t}^{G}\\ f_{t}^{N}\\ f_{t}^{R} \end{pmatrix} + \varepsilon_{t}$$

$$(13)$$

em que

$$\Lambda = \begin{pmatrix} \Lambda_{N,G} & \Lambda_{N,N} & 0\\ \Lambda_{R,G} & 0 & \Lambda_{R,R} \end{pmatrix} \tag{14}$$

$$f_t = \begin{pmatrix} f_t^G \\ f_t^N \\ f_t^R \end{pmatrix} \tag{15}$$

O fator global é estimado considerando todas as variáveis explicativas. Já os fatores nominal e real são estimados considerando apenas, respectivamente, as variáveis classificadas em nominais e reais. O parâmetro μ é um vetor de dimensão N de constantes.

Banbura et al. (2011) utilizam uma especificação diferente para o DFM que não é na forma exata, permitindo autocorrelação serial nos componentes idiossincráticos, no qual cada um segue isoladamente um AR(1):

$$\varepsilon_{i,t} = \alpha_i \epsilon_{i,t-1} + e_{i,t}, \quad e_{i,t} \sim i.i.d.N(0, \sigma_i^2)$$
 (16)

com $E[e_{i,t}e_{j,s}] = 0$ para $i \neq j$.

Uma outra novidade no modelo é que o vetor de séries x_t é composto por variáveis mensais e por uma medida mensal não observada do PIB. O que torna obsoleta a necessidade da equação (11) uma vez que séries de diferentes frequências são incorparadas conjuntamente no processo gerador.

Neste modelo os parâmetros, os fatores comuns e o PIB mensal não são observados, porém todos são estimados conjuntamente utilizando o *Expected Maximization algorithm*. Esse algoritmo utiliza a seguinte estrutura recursiva:

- E-step: A esperança da função de verossimilhança condicional é calculada utilizando as estimativas dos parâmetros estáticos (θ) da iteração anterior, θ_j ;
- M-step: Os novos parâmetros, θ_{j+1} são estimados pela maximização da função de verossimilhança do passo anterior, com respeito a θ .

O algoritmo então converge até que os parâmetros sejam iguais nas iterações. O processo recursivo se inicia com as estimativas de PCA apresentadas em Giannone et al. (2008) (primeiro estágio do método Two Stages).

2.4 Base de dados

Tabela 1: Data base.

Series code	Series name	Transformation	Delay
serie1	Exchange rate- Free- United States dollar (sale)-1 u.m.c/US\$	1	0
serie12	Interest rate- CDI	1	0
serie188	National Consumer Price Index (INPC)	4	14
serie189	General Price Index-Market (IGP-M)	0	0
serie192	National Index of Building Costs (INCC)	4	0
serie193	Consumer Price Index- Sao Paulo (IPC-FIPE)	4	7
serie194	Cost of Living Index (ICV-Dieese)	4	7
serie206	Staple food basket u.m.c	1	7
serie225	Wholesale Price Index (IPA)	0	14
serie432	Interest rate- Selic target	1	0
serie433	Broad National Consumer Price Index (IPCA)	4	7
serie1178	Interest rate- Selic in annual terms (basis 252)	4	0
serie1344	Installed capacity utilization- General(FGV)	3	0
serie1373	vehicle production (total)	3	14
serie1374	passenger cars and light commercial vehicles production	3	14
serie1375	truck production	3	14
serie1376	bus production	3	14
serie1377	motorcycle production	3	14
serie1378	vehicle sales (total)	3	14
serie1379	domestic vehicle sales	3	14
serie1380	vehicle exports	3	14
serie1382	productions of mechanised cultivators	4	14
serie1383	four wheel tractor production	3	14
serie1384	track driven tractor production	3	14
serie1385	production of combined harvesters	3	14
serie1386	production of mechanical diggers	3	14
Continued on next page 1			

Continued on next page |

Tabela 1 – continued from previous page

Series code	Series name	Transformation	Delay
serie1387	other agricultural machinery	3	14
serie1388	production of agricultural machinery (total)	3	14
serie1389	petroleum derivatives production- crude oil	1	42
serie1390	petroleum derivatives production- LGN	1	42
serie1391	petroleum derivatives production- total	1	42
serie1392	petroleum derivatives production- natural gas	1	42
serie1402	electric energy consumption- Brazil- commercial	3	42
serie1403	electric energy consumption- Brazil- residential	3	42
serie1404	eletric energy consumption- Brazil- industrial	3	42
${\rm serie} 1405$	eletric energy consumption- Brazil- other	3	42
serie1406	eletric energy consumption- Brazil- total	3	42
serie1453	Credit sales Index	3	21
serie1454	Cash Sales Index	3	21
serie1455	sales volume index in the retail sector- Total- Brazil	3	70
serie1483	sales volume index in the retail sector- Fuel and lubricants- Brazil	3	70
serie1496	sales volume index in the retail sector- Hypermarkets, supermarket, food, beverages and tobacco- Brazil	3	70
serie1509	sales volume index in the retail sector- Textiles, Clothing and Footwear- Brazil	3	70
serie1522	sales volume index in the retail sector- Furniture and white goods- Brazil	3	70
serie1548	sales volume index in the retail sector- Vehicles and motorcycles, spare parts- Brazil	3	70
serie1561	sales volume index in the retail sector- Hypermarkets, supermarket- Brazil	3	70
serie2053	Net public debt- Balances in c.m.u. (million) - Total- Federal Government and Banco Central	1	35
serie2057	Net public debt- Balances in c.m.u. (million) - Total- State governments	1	35
serie2058	Net public debt- Balances in c.m.u. (million) - Total- Municipal governments	1	35
serie4393	Consumer confidence index	3	14
serie4394	Current economic conditions index	3	14
serie4395	future expectations index	1	14

Continued on next page

Tabela 1 – continued from previous page

Series code	Series name	Transformation	Delay
serie4503	net public debt (%GDP)- total- Federal Government and Banco Central	2	35
serie4506	net public debt (% GDP)- Total- State and municipal governments	2	35
serie4507	net public debt (%GDP)- total- State governments	2	35
serie4508	net public debt (% GDP)- total- Municipal governments	2	35
serie4509	net public debt (%GDP)- total- State enterprises	2	35
serie4513	net public debt(%GDP)- total- consolidated public sector	2	35
serie7341	Business confidence index- General	1	0
serie7357	steel production (1992= 100)	3	42
serie7384	sales of factory authorized vehicle outlets- Passenger cars sales	3	7
serie7385	sales of factory authorized vehicle outlets- Light commercial cars sales	3	7
serie7386	sales of factory authorized vehicle outlets- Truck sales	3	7
serie7412	balanced checks - in 1000	3	98
serie7413	returned checks - in 1000	3	98
serie7415	BNDES system disbursements- Total	3	21
serie7416	BNDES system disbursements- Manufacturing industry	3	21
serie7417	BNDES system disbursements- Commerce and Services	3	21
serie7418	BNDES system disbursements- Agricultural sector	3	21
serie7419	BNDES system disbursements- Vegetable extraction	3	21
serie7478	National consumer Price Index- Extended 15 (IPCA-15)	0	0
serie7495	SINAPI	0	14
serie7832	Ibovespa- monthly percent change	0	14
serie 13667	Percent of 90 days past due loans of financial institutions under public control - Total	1	14
serie 13673	Percent of 90 days past due loans of financial institutions under national private control - Total	1	14
serie 13679	Percent of 90 days past due loans of financial institutions under foreign control - Total	1	14
serie 13685	Percent of 90 days past due loans of financial institutions under private control - Total	1	14
serie20048	Commodity Index - Brazil (until Nov/2017)	1	14
		Continued on next page	

Continued on next page

Tabela 1 – continued from previous page

Series code	Series name	Transformation	Delay
serie20050	Commodity Index - Brazil Agriculture (until Nov/2017)	1	14
${\rm serie} 20051$	Commodity Index - Brazil metal (until $Nov/2017$)	1	14
${\rm serie} 20052$	Commodity Index - Brazil Energy (until Nov/2017)	1	14
serie20099	Pharmac., medical, orthop, and perfumery articles	3	70
serie20101	Books, newspaper, megazines	3	70
serie20102	Office, comp./ comunic, equip	3	70
serie20104	Other art. Of personal use	3	70
${\rm serie} 20105$	Building materials	3	70
serie20106	Broad trade sector	3	70
serie 20339	Sondagem de serviços - Índice de Confiança de Serviços- Dessazonalizado	1	7
serie 20340	Sondagem de Serviços - Índice de Expectativas (IE-S) - Dessazonalizado	1	7
serie 20341	Residential Real Estate Collateral Value Index	1	98
serie 21637	PMS- Nominal revenue from services - Total - Brazil	3	42
serie21859	General (2012=100)	3	35
serie21861	Physical Production- Mineral extraction	3	35
serie21862	Physical Production - Manufacturing Industry	3	35
serie21863	Physical Production - Capital goods	3	35
serie21864	Physical Production- Intermediate goods	3	35
${\rm serie} 21865$	Physical Production - Consumer goods	3	35
serie21866	Physical Production - Durable goods	3	35
serie 21867	Physical Production - Semi durable and nondurable goods	3	35
serie21868	Physical Production - Production of construction inputs	3	35
serie21924	Industrial Production (2012=100)- Southeast Region	3	35
serie21930	Industrial Production (2012=100)- Northern Region	3	35
serie21934	Industrial Production (2012=100)- South	3	35
serie21939	Industrial Production (2012=100)- Central- Western Region	3	35
		inued on next page	

Continued on next page

Tabela 1 – continued from previous page

Series code	Series name	Transformation	Delay
serie21961	Industrial Production (2012=100)- Northeast	3	35
serie22099	Quaterly GDP- observed data- GDP at market prices	3	70
serie22109	Quaterly GDP - seasonally adjusted data - GDP at market prices	1	70
serie22704	Balance on goods and services - monthly - net	3	21
serie22705	Balance on goods and services - monthly - credit	3	21
serie22706	Balance on goods and services - monthly - debit	3	21
serie22707	Balance on goods- Balance of Payments - monthly- net	3	21
serie24352	capacity utilization- manufacturing industry (FGV)	1	21
serie24369	unemployment - PNAD	3	28
serie24370	Working age populaton - Continuous PNAD	1	28
serie24378	Labor force population - Continuous PNAD	1	28
serie24379	employed population - Continuous PNAD	3	28
serie24382	real habitually average earnings of employed people- Continuous PNAD	1	28
serie25241	registered employees Index - Manufacturing	3	28
ICI	ICI with seasonal adjust - Industry confidence index	1	0
ISA	ISA with seasonal adjust - Industry confidence index - Actual situation	1	0
IE	IE with seasonal adjust - Industry confidence index - Expectation	1	0
ICOM	ICOM with seasonal adjust-Retail sector extended index	1	0
ISACOM	ISA-COM with seasonal adjust-Retail sector extended actual situtation index	1	0
IECOM	IE-COM with seasonal adjust-Retail sector extended expected index	1	0
ICS	ICS with seasonal adjust - Service confidence index	1	0
ISAS	ISA-S with seasonal adjust - Service confidence index- Actual situation	1	0
IES	IE-S with seasonal adjust - Service confidence index- Expectiation	1	0

3 Nowcasting do PIB brasileiro

apresentar a ordem de cada modelo e quais variáveis análise pseudo fora da amostra para avaliar a previsão do PIB avaliar como a divulgação das variáveis impactam na previsão do PIB previsão do PIB 2018 mostrar link do shiny com a atualização da previsão atual, realtime

4 Considerações finais

concluir o trabalho e apresentar trabalhos futuros

Referências

- Banbura, M., Giannone, D., & Reichlin, L. (2011). Nowcasting. Oxford Handbook on Economic Forecasting.
- Bańbura, M., & Rünstler, G. (2011). A look into the factor model black box: publication lags and the role of hard and soft data in forecasting gdp. *International Journal of Forecasting*, 27(2), 333–346.
- Giannone, D., Reichlin, L., & Small, D. (2008). Nowcasting: The real-time informational content of macroeconomic data. *Journal of Monetary Economics*, 55(4), 665–676.
- Mariano, R. S., & Murasawa, Y. (2003). A new coincident index of business cycles based on monthly and quarterly series. *Journal of applied Econometrics*, 18(4), 427–443.
- Stock, J. H., & Watson, M. (2011). Dynamic factor models. Oxford Handbook on Economic Forecasting.
- Stock, J. H., & Watson, M. W. (2006). Forecasting with many predictors. *Handbook of economic forecasting*, 1, 515–554.