

# Nowcasting Brasil

Pedro G. Costa Ferreira

FGV IBRE

Daiane Marcolino de Mattos

FGV IBRE

Guilherme Branco Gomes

FGV EPGE

Tiago dos Guaranys Martins

FGV EPGE

## Resumo

Inserir resumo aqui

Palavras-chave: nowcasting, PIB, dynamic factors model.

## 1 Introdução

Decisões de política monetária e investimento são tomadas com base nas condições presentes e futuras da economia mesmo quando as variáveis usadas para descrever esse estado não estão acessíveis. **falar da defasagem do PIB do Brasil**. Por conta disso, a previsão em tempo real, ou simplesmente *nowcasting*, se torna um tema de relevância.

Os métodos de previsão em tempo real, que se desenvolveram nas últimas décadas, são baseados em modelos de fatores dinâmicos (DFM) e dependem de algum poder computacional para lidar com uma grande quantidade de dados. Veja **Stock & Watson (2006)** para uma revisão a respeito dessa literatura.

O termo nowcasting é cunhado em **Giannone et al. (2008)** e definido como a previsão do presente, do passado recente ou do futuro próximo. Neste artigo, os autores mostram como reduzir em apenas dois fatores dinâmicos a informação contida em dezenas de séries temporais mensais com o intuito de explicar o PIB (dos Estados Unidos) de curto prazo dos trimestres cuja informação ainda não está disponível. Após esse estudo, muitos outros continuaram explorando o uso de DFM na previsão em tempo real, como por exemplo **Bańbura & Rünstler (2011)** e **Banbura et al. (2011)**. No primeiro os autores fazem uma análise mostrando como a divulgação de certas variáveis influenciam na atualização da previsão do PIB. Além disso, os autores também propõem uma medida mensal para a variável trimestral, uma vez que os fatores extraídos são mensais. No segundo, os autores propõem estimar o modelo via outro método (Expectation Maximization) e não mais por dois estágios como se fazia em **Giannone et al. (2008)**.

O objetivo do artigo é encontrar um modelo de previsão para o PIB do Brasil segundo as propostas desenvolvidas nos artigos do parágrafo anterior. Para disseminar o uso da metodologia e reproduzir esse

---

Somos gratos a Domenico Giannone por disponibilizar os códigos em Matlab, assim como comentários relevantes sobre a bibliografia.

trabalho, desenvolveu-se o pacote `nowcasting` no R com tais métodos e algumas outras ferramentas que facilitam o tratamento de séries temporais para tal uso e que permitem analisar a importância de cada variável numa previsão. As funções de estimação foram apenas traduzidas para a linguagem, uma vez que [Giannone et al. \(2008\)](#) e [Banbura et al. \(2011\)](#) forneceram os códigos em `Matlab`.

A estrutura do artigo é a seguinte: na seção 2 são apresentados o arcabouço teórico sobre modelos de fatores dinâmicos, os métodos de estimação e a base de dados; na seção 3 tem-se os resultados da aplicação metodológica, a análise dos resultados e previsão estendida para o PIB do Brasil no ano de 2018. Por fim, na seção 4, têm-se as considerações finais. Embora todo o contexto apresentado aqui seja referente ao PIB, a metodologia pode ser aplicada a outras séries temporais.

## 2 Metodologia

### 2.1 Modelo de Fatores Dinâmicos

Seja  $x_t = (x_{1,t}, x_{2,t}, \dots, x_{N,t})'$  o vetor que representa as  $N$  séries temporais mensais transformadas para satisfazerem a suposição de estacionariedade. A especificação geral do modelo de fator dinâmico (DFM em inglês) é dada por:

$$x_t = \mu + \Lambda f_t + \varepsilon_t \quad (1)$$

$$f_t = \sum_{i=1}^p A_i f_{t-i} + B u_t, \quad u_t \sim NID(0, I_q) \quad (2)$$

em que  $\mu$  é o vetor de médias incondicionais,  $f_t$  é o vetor de fatores comuns (não observados) de dimensão  $r \times 1$  modelados por um processo VAR(p) em que as matrizes  $A_i$  de dimensão  $r \times r$  representam os coeficientes do processo autorregressivo e  $B$  de dimensão  $r \times q$ ,  $\Lambda$  é uma matriz de constantes de dimensão  $N \times r$  e  $\varepsilon_t$  é um vetor de componentes idiossincráticos, tal que  $\Psi = E[\varepsilon_t \varepsilon_t']$ . Assume-se ainda que  $E[\varepsilon_t u_{t-k}'] = 0$  para qualquer  $k$ .

No chamado *modelo de fatores dinâmicos exato* assume-se que os componentes de erro são mutuamente não correlacionados em todos os lags, isto é,  $E[\varepsilon_{i,t} \varepsilon_{j,s}] = 0$  para  $i \neq j$ . No entanto, é possível que a componente idiossincrática siga um processo AR(p) tal como se mostra na equação (3). Tal procedimento é encontrado com mais detalhes em [Banbura et al. \(2011\)](#).

$$\varepsilon_{i,t} = \sum_{i=1}^p \alpha_i \varepsilon_{i,t-i} + e_{i,t}, \quad e_{i,t} \sim NID(0, \sigma_i^2) \quad (3)$$

em que  $E[e_{i,t} e_{j,s}] = 0$  para  $i \neq j$ .

Veja um exemplo da representação matricial da equação 2 do modelo apresentado considerando as

ordens  $r = 2$ ,  $p = 2$  e  $q = 2$ .

$$\begin{bmatrix} f_{1,t} \\ f_{2,t} \\ f_{1,t-1} \\ f_{2,t-1} \end{bmatrix} = \begin{bmatrix} a_{1,1}^1 & a_{1,2}^1 & a_{1,1}^2 & a_{1,2}^2 \\ a_{2,1}^1 & a_{2,2}^1 & a_{2,1}^2 & a_{2,2}^2 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} f_{1,t-1} \\ f_{2,t-1} \\ f_{1,t-2} \\ f_{2,t-2} \end{bmatrix} + \begin{bmatrix} b_{1,1} & b_{1,2} \\ b_{2,1} & b_{2,2} \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} u_{1,t} \\ u_{2,t} \end{bmatrix} \quad (4)$$

$$F_t = \begin{bmatrix} A_1 & A_2 \\ I_2 & 0 \end{bmatrix} F_{t-1} + B u_t \quad (5)$$

## 2.2 Variáveis trimestrais e mensais

Para que a modelagem apresentada suporte frequências mensais e trimestrais, é utilizada a transformação proposta em [Mariano & Murasawa \(2003\)](#). Assim é possível que variáveis trimestrais como PIB sejam explicadas por outras variáveis de frequências mensais (fatores) ao se obter representações trimestrais para a variável mensal.

Seja  $Y_t^M$  o nível de uma variável mensal que representa o fluxo. A representação trimestral dessa variável  $Y_t^Q$  é dada por:

$$Y_t^Q = Y_t^M + Y_{t-1}^M + Y_{t-2}^M, \quad t = 3, 6, 9, \dots \quad (6)$$

Defina  $y_t = Y_t^M - Y_{t-1}^M$  e  $y_t^Q = Y_t^Q - Y_{t-3}^Q$ . Desse modo pode-se escrever  $y_t^Q$  em função de  $y_t$  de acordo com o seguinte filtro:

$$y_t^Q = y_t + 2y_{t-1} + 3y_{t-2} + 2y_{t-3} + y_{t-4}, \quad t = 3, 6, 9, \dots \quad (7)$$

Assim é possível transformar diferenças mensais em diferenças trimestrais. Além disso, se a variável de interesse for uma taxa de variação, tal filtro é uma possível aproximação:

$$\log(y_t^Q) \approx \log(y_t) + 2\log(y_{t-1}) + 3\log(y_{t-2}) + 2\log(y_{t-3}) + \log(y_{t-4}) \quad (8)$$

## 2.3 Estimação

Serão descritas duas metodologias para estimação de fatores dinâmicos: *Two Stages* e *Expectation & Maximization*. No primeiro método considera-se que as variáveis explicativas em  $x_t$  sejam de mesma periodicidade (mensal) e a variável resposta de periodicidade trimestral. No segundo método,  $x_t$  e  $y_t$  são de periodicidade mensal.

1. *Two Stages*: Essa abordagem é apresentada no trabalho seminal de [Giannone et al. \(2008\)](#). Considerando o modelo de fatores dinâmicos exato, a estimação dos fatores dinâmicos é feita em duas etapas.

No primeiro estágio, utilizando um painel  $(\bar{X}_t)$  balanceado e padronizado, são estimados os parâmetros das matrizes  $\Lambda$  e  $f_t$  via PCA (Principal Components Analysis). Por balanceado entende-se as variáveis em  $x_t$  sem missings e outliers. A padronização é importante pois a

estimação via PCA não é invariante a escala. Os estimadores  $\hat{\Lambda}$  e  $\hat{f}_t$  podem ser obtidos resolvendo o problema de otimização em (9).

$$\min_{f_1, \dots, f_T, \Lambda} \frac{1}{NT} \sum_{t=1}^T (\bar{X}_t - \Lambda f_t)' (\bar{X}_t - \Lambda f_t) \quad s.t. \quad N^{-1} \Lambda' \Lambda = I_r \quad (9)$$

Em seguida, o estimador da matriz de variância e covariância de  $\varepsilon_t$  é dado por

$$\hat{\Psi} = diag \left( \frac{1}{T} \sum_{t=1}^T (\bar{X}_t - \hat{\Lambda} \hat{f}_t) (\bar{X}_t - \hat{\Lambda} \hat{f}_t)' \right) \quad (10)$$

De acordo com [Stock & Watson \(2011\)](#), a solução de (9) é tal que  $\hat{\Lambda}$  são os autovetores da matriz de variância e covariância de  $\bar{X}_t$  associados aos  $r$  maiores autovalores e  $\hat{f}_t$  são as  $r$  primeiras componentes principais de  $\bar{X}_t$ . Os coeficientes das matrizes  $A_i$ ,  $i = 1, 2, \dots, p$  são estimados por OLS ao regredir  $f_t$  em  $f_{t-1}, \dots, f_{t-p}$ . Por fim  $BB'$  é estimado como sendo a matriz de covariância dos resíduos dessa regressão.

No segundo estágio, utiliza-se Kalman smoothing para reestimar os fatores para o painel não balanceado  $x_t$  considerando os parâmetros obtidos na etapa anterior.

Nesse contexto, duas opções podem ser consideradas ao estimar os fatores:

- *quarterly factors*: as variáveis explicativas mensais podem ser transformadas para representarem quantidades trimestrais seguindo o procedimento visto na seção ???. Portanto, os fatores embora mensais também representarão quantidades trimestrais e, conseqüentemente, poderão ser transformados em variáveis de periodicidade trimestral, e assim a equação (11) pode ser estimada para a previsão da variável resposta.
- *monthly factors*: outra opção é estimar os fatores sobre as variáveis originais e ao final aplicar a transformação vista na seção ??? aos fatores para que representem quantidades trimestrais. Em seguida cria-se a variável de periodicidade trimestral que será usada para a previsão da variável resposta em (11).

$$y_t = \beta_0 + \beta' \hat{f}_t + e_t \quad (11)$$

Os parâmetros da equação (11) são estimados por OLS e a previsão de  $y_{t+h}$  é obtida como

$$\hat{y}_{t+h} = \hat{\beta}_0 + \hat{\beta}' \hat{f}_{t+h} \quad (12)$$

2. Expectation & Maximization: [Banbura et al. \(2011\)](#) apresentam novidades metodológicas, tanto na especificação do modelo quanto na estimação.

Primeiramente são impostas restrições com relação aos fatores. Os fatores são divididos em três

grupos: global, real e nominal, de modo que a equação (1) pode ser reescrita como:

$$x_t = \mu + \begin{pmatrix} \Lambda_{N,G} & \Lambda_{N,N} & 0 \\ \Lambda_{R,G} & 0 & \Lambda_{R,R} \end{pmatrix} \begin{pmatrix} f_t^G \\ f_t^N \\ f_t^R \end{pmatrix} + \varepsilon_t \quad (13)$$

em que

$$\Lambda = \begin{pmatrix} \Lambda_{N,G} & \Lambda_{N,N} & 0 \\ \Lambda_{R,G} & 0 & \Lambda_{R,R} \end{pmatrix} \quad (14)$$

$$f_t = \begin{pmatrix} f_t^G \\ f_t^N \\ f_t^R \end{pmatrix} \quad (15)$$

O fator global é estimado considerando todas as variáveis explicativas. Já os fatores nominal e real são estimados considerando apenas, respectivamente, as variáveis classificadas em nominais e reais. O parâmetro  $\mu$  é um vetor de dimensão N de constantes.

Banbura et al. (2011) utilizam uma especificação diferente para o DFM que não é na forma exata, permitindo autocorrelação serial nos componentes idiossincráticos, no qual cada um segue isoladamente um  $AR(1)$ :

$$\varepsilon_{i,t} = \alpha_i \varepsilon_{i,t-1} + e_{i,t}, \quad e_{i,t} \sim i.i.d. N(0, \sigma_i^2) \quad (16)$$

com  $E[e_{i,t}e_{j,s}] = 0$  para  $i \neq j$ .

Uma outra novidade no modelo é que o vetor de séries  $x_t$  é composto por variáveis mensais e por uma medida mensal não observada do PIB. O que torna obsoleta a necessidade da equação (11) uma vez que séries de diferentes frequências são incorporadas conjuntamente no processo gerador.

Neste modelo os parâmetros, os fatores comuns e o PIB mensal não são observados, porém todos são estimados conjuntamente utilizando o *Expected Maximization algorithm*. Esse algoritmo utiliza a seguinte estrutura recursiva:

- E-step: A esperança da função de verossimilhança condicional é calculada utilizando as estimativas dos parâmetros estáticos ( $\theta$ ) da iteração anterior,  $\theta_j$ ;
- M-step: Os novos parâmetros,  $\theta_{j+1}$  são estimados pela maximização da função de verossimilhança do passo anterior, com respeito a  $\theta$ .

O algoritmo então converge até que os parâmetros sejam iguais nas iterações. O processo recursivo se inicia com as estimativas de PCA apresentadas em Giannone et al. (2008) (primeiro estágio do método *Two Stages*).

## 2.4 Base de dados

inserir base de dados

## 3 Nowcasting do PIB brasileiro

apresentar a ordem de cada modelo e quais variáveis

análise pseudo fora da amostra para avaliar a previsão do PIB

avaliar como a divulgação das variáveis impactam na previsão do PIB

previsão do PIB 2018

mostrar link do shiny com a atualização da previsão atual, realtime

## 4 Considerações finais

concluir o trabalho e apresentar trabalhos futuros

## Referências

- Banbura, M., Giannone, D., & Reichlin, L. (2011). Nowcasting. *Oxford Handbook on Economic Forecasting*.
- Bañbura, M., & Rünstler, G. (2011). A look into the factor model black box: publication lags and the role of hard and soft data in forecasting gdp. *International Journal of Forecasting*, 27(2), 333–346.
- Giannone, D., Reichlin, L., & Small, D. (2008). Nowcasting: The real-time informational content of macroeconomic data. *Journal of Monetary Economics*, 55(4), 665–676.
- Mariano, R. S., & Murasawa, Y. (2003). A new coincident index of business cycles based on monthly and quarterly series. *Journal of applied Econometrics*, 18(4), 427–443.
- Stock, J. H., & Watson, M. (2011). Dynamic factor models. *Oxford Handbook on Economic Forecasting*.
- Stock, J. H., & Watson, M. W. (2006). Forecasting with many predictors. *Handbook of economic forecasting*, 1, 515–554.