

Nowcasting Brasil

Pedro G. Costa Ferreira

FGV IBRE

Daiane Marcolino de Mattos

FGV IBRE

Guilherme Branco Gomes

FGV EPGE

Tiago dos Guaranys Martins

FGV EPGE

Resumo

Inserir resumo aqui

Palavras-chave: nowcasting, PIB, dynamic factors model.

1 Introdução

Decisões de política monetária e investimento são tomadas com base nas condições presentes e futuras da economia mesmo quando as variáveis usadas para descrever esse estado não estão acessíveis. Esse é particularmente o caso do PIB do Brasil que é divulgado, em média, 60 dias após o trimestre de referência. Por conta disso, a previsão em tempo real, ou simplesmente *nowcasting*, se torna um tema de relevância.

Os métodos de previsão em tempo real, que se desenvolveram nas últimas décadas, são baseados em modelos de fatores dinâmicos (DFM) e dependem de algum poder computacional para lidar com uma grande quantidade de dados. Veja [Stock & Watson \(2006\)](#) para uma revisão a respeito dessa literatura.

O termo nowcasting é cunhado em [Giannone et al. \(2008\)](#) e definido como a previsão do presente, do passado recente ou do futuro próximo. Neste artigo, os autores mostram como reduzir em apenas dois fatores dinâmicos a informação contida em dezenas de séries temporais mensais com o intuito de explicar o PIB (dos Estados Unidos) de curto prazo dos trimestres cuja informação ainda não está disponível. Após esse estudo, muitos outros continuaram explorando o uso de DFM na previsão em tempo real, como por exemplo [Bańbura & Rünstler \(2011\)](#) e [Banbura et al. \(2011\)](#). No primeiro os autores fazem uma análise mostrando como a divulgação de certas variáveis influenciam na atualização da previsão do PIB. Além disso, os autores também propõem uma medida mensal para a variável trimestral, uma vez que os fatores extraídos são mensais. No segundo, os autores propõem estimar o modelo via outro método (Expectation Maximization) e não mais por dois estágios como se fazia em [Giannone et al. \(2008\)](#).

O objetivo do artigo é encontrar um modelo de previsão para o PIB do Brasil segundo as propostas desenvolvidas nos artigos do parágrafo anterior. Para disseminar o uso da metodologia e reproduzir esse

Somos gratos a Domenico Giannone por disponibilizar os códigos em Matlab, assim como comentários relevantes sobre a bibliografia.

trabalho, desenvolveu-se o pacote `nowcasting` no R com tais métodos e algumas outras ferramentas que facilitam o tratamento de séries temporais para tal uso e que permitem analisar a importância de cada variável numa previsão. As funções de estimação foram apenas traduzidas para a linguagem, uma vez que [Giannone et al. \(2008\)](#) e [Banbura et al. \(2011\)](#) forneceram os códigos em `Matlab`.

A estrutura do artigo é a seguinte: na seção 2 são apresentados o arcabouço teórico sobre modelos de fatores dinâmicos, os métodos de estimação e a base de dados; na seção 3 tem-se os resultados da aplicação metodológica, a análise dos resultados e previsão estendida para o PIB do Brasil no ano de 2018. Por fim, na seção 4, têm-se as considerações finais. Embora todo o contexto apresentado aqui seja referente ao PIB, a metodologia pode ser aplicada a outras séries temporais.

2 Metodologia

2.1 Modelo de Fatores Dinâmicos

Seja $x_t = (x_{1,t}, x_{2,t}, \dots, x_{N,t})'$ o vetor que representa as N séries temporais mensais transformadas para satisfazerem a suposição de estacionariedade. A especificação geral do modelo de fator dinâmico (DFM em inglês) é dada por:

$$x_t = \mu + \Lambda f_t + \varepsilon_t \quad (1)$$

$$f_t = \sum_{i=1}^p A_i f_{t-i} + B u_t, \quad u_t \sim NID(0, I_q) \quad (2)$$

em que μ é o vetor de médias incondicionais, f_t é o vetor de fatores comuns (não observados) de dimensão $r \times 1$ modelados por um processo VAR(p) em que as matrizes A_i de dimensão $r \times r$ representam os coeficientes do processo autorregressivo e B de dimensão $r \times q$, Λ é uma matriz de constantes de dimensão $N \times r$ e ε_t é um vetor de componentes idiossincráticos, tal que $\Psi = E[\varepsilon_t \varepsilon_t']$. Assume-se ainda que $E[\varepsilon_t u_{t-k}'] = 0$ para qualquer k .

No chamado *modelo de fatores dinâmicos exato* assume-se que os componentes de erro são mutuamente não correlacionados em todos os lags, isto é, $E[\varepsilon_{i,t} \varepsilon_{j,s}] = 0$ para $i \neq j$. No entanto, é possível que a componente idiossincrática siga um processo AR(p) tal como se mostra na equação (3). Tal procedimento é encontrado com mais detalhes em [Banbura et al. \(2011\)](#).

$$\varepsilon_{i,t} = \sum_{i=1}^p \alpha_i \varepsilon_{i,t-i} + e_{i,t}, \quad e_{i,t} \sim NID(0, \sigma_i^2) \quad (3)$$

em que $E[e_{i,t} e_{j,s}] = 0$ para $i \neq j$.

Veja um exemplo da representação matricial da equação 2 do modelo apresentado considerando as

ordens $r = 2$, $p = 2$ e $q = 2$.

$$\begin{bmatrix} f_{1,t} \\ f_{2,t} \\ f_{1,t-1} \\ f_{2,t-1} \end{bmatrix} = \begin{bmatrix} a_{1,1}^1 & a_{1,2}^1 & a_{1,1}^2 & a_{1,2}^2 \\ a_{2,1}^1 & a_{2,2}^1 & a_{2,1}^2 & a_{2,2}^2 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} f_{1,t-1} \\ f_{2,t-1} \\ f_{1,t-2} \\ f_{2,t-2} \end{bmatrix} + \begin{bmatrix} b_{1,1} & b_{1,2} \\ b_{2,1} & b_{2,2} \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} u_{1,t} \\ u_{2,t} \end{bmatrix} \quad (4)$$

$$F_t = \begin{bmatrix} A_1 & A_2 \\ I_2 & 0 \end{bmatrix} F_{t-1} + B u_t \quad (5)$$

2.2 Variáveis trimestrais e mensais

Para que a modelagem apresentada suporte frequências mensais e trimestrais, é utilizada a transformação proposta em [Mariano & Murasawa \(2003\)](#). Assim é possível que variáveis trimestrais como PIB sejam explicadas por outras variáveis de frequências mensais (fatores) ao se obter representações trimestrais para a variável mensal.

Seja Y_t^M o nível de uma variável mensal que representa o fluxo. A representação trimestral dessa variável Y_t^Q é dada por:

$$Y_t^Q = Y_t^M + Y_{t-1}^M + Y_{t-2}^M, \quad t = 3, 6, 9, \dots \quad (6)$$

Defina $y_t = Y_t^M - Y_{t-1}^M$ e $y_t^Q = Y_t^Q - Y_{t-3}^Q$. Desse modo pode-se escrever y_t^Q em função de y_t de acordo com o seguinte filtro:

$$y_t^Q = y_t + 2y_{t-1} + 3y_{t-2} + 2y_{t-3} + y_{t-4}, \quad t = 3, 6, 9, \dots \quad (7)$$

Assim é possível transformar diferenças mensais em diferenças trimestrais. Além disso, se a variável de interesse for uma taxa de variação, tal filtro é uma possível aproximação:

$$\log(y_t^Q) \approx \log(y_t) + 2\log(y_{t-1}) + 3\log(y_{t-2}) + 2\log(y_{t-3}) + \log(y_{t-4}) \quad (8)$$

2.3 Estimação

Serão descritas duas metodologias para estimação de fatores dinâmicos: *Two Stages* e *Expectation & Maximization*. No primeiro método considera-se que as variáveis explicativas em x_t sejam de mesma periodicidade (mensal) e a variável resposta de periodicidade trimestral. No segundo método, x_t e y_t são de periodicidade mensal.

1. *Two Stages*: Essa abordagem é apresentada no trabalho seminal de [Giannone et al. \(2008\)](#). Considerando o modelo de fatores dinâmicos exato, a estimação dos fatores dinâmicos é feita em duas etapas.

No primeiro estágio, utilizando um painel (\bar{X}_t) balanceado e padronizado, são estimados os parâmetros das matrizes Λ e f_t via PCA (Principal Components Analysis). Por balanceado entende-se as variáveis em x_t sem missings e outliers. A padronização é importante pois a

estimação via PCA não é invariante a escala. Os estimadores $\hat{\Lambda}$ e \hat{f}_t podem ser obtidos resolvendo o problema de otimização em (9).

$$\min_{f_1, \dots, f_T, \Lambda} \frac{1}{NT} \sum_{t=1}^T (\bar{X}_t - \Lambda f_t)' (\bar{X}_t - \Lambda f_t) \quad s.t. \quad N^{-1} \Lambda' \Lambda = I_r \quad (9)$$

Em seguida, o estimador da matriz de variância e covariância de ε_t é dado por

$$\hat{\Psi} = diag \left(\frac{1}{T} \sum_{t=1}^T (\bar{X}_t - \hat{\Lambda} \hat{f}_t) (\bar{X}_t - \hat{\Lambda} \hat{f}_t)' \right) \quad (10)$$

De acordo com [Stock & Watson \(2011\)](#), a solução de (9) é tal que $\hat{\Lambda}$ são os autovetores da matriz de variância e covariância de \bar{X}_t associados aos r maiores autovalores e \hat{f}_t são as r primeiras componentes principais de \bar{X}_t . Os coeficientes das matrizes A_i , $i = 1, 2, \dots, p$ são estimados por OLS ao regredir f_t em f_{t-1}, \dots, f_{t-p} . Por fim BB' é estimado como sendo a matriz de covariância dos resíduos dessa regressão.

No segundo estágio, utiliza-se Kalman smoothing para reestimar os fatores para o painel não balanceado x_t considerando os parâmetros obtidos na etapa anterior.

Nesse contexto, duas opções podem ser consideradas ao estimar os fatores:

- *quarterly factors*: as variáveis explicativas mensais podem ser transformadas para representarem quantidades trimestrais seguindo o procedimento visto na seção 2.2. Portanto, os fatores embora mensais também representarão quantidades trimestrais e, conseqüentemente, poderão ser transformados em variáveis de periodicidade trimestral, e assim a equação (11) pode ser estimada para a previsão da variável resposta.
- *monthly factors*: outra opção é estimar os fatores sobre as variáveis originais e ao final aplicar a transformação vista na seção 2.2 aos fatores para que representem quantidades trimestrais. Em seguida cria-se a variável de periodicidade trimestral que será usada para a previsão da variável resposta em (11).

$$y_t = \beta_0 + \beta' \hat{f}_t + e_t \quad (11)$$

Os parâmetros da equação (11) são estimados por OLS e a previsão de y_{t+h} é obtida como

$$\hat{y}_{t+h} = \hat{\beta}_0 + \hat{\beta}' \hat{f}_{t+h} \quad (12)$$

2. Expectation & Maximization: [Banbura et al. \(2011\)](#) apresentam novidades metodológicas, tanto na especificação do modelo quanto na estimação.

Primeiramente são impostas restrições com relação aos fatores. Os fatores são divididos em três

grupos: global, real e nominal, de modo que a equação (1) pode ser reescrita como:

$$x_t = \mu + \begin{pmatrix} \Lambda_{N,G} & \Lambda_{N,N} & 0 \\ \Lambda_{R,G} & 0 & \Lambda_{R,R} \end{pmatrix} \begin{pmatrix} f_t^G \\ f_t^N \\ f_t^R \end{pmatrix} + \varepsilon_t \quad (13)$$

em que

$$\Lambda = \begin{pmatrix} \Lambda_{N,G} & \Lambda_{N,N} & 0 \\ \Lambda_{R,G} & 0 & \Lambda_{R,R} \end{pmatrix} \quad (14)$$

$$f_t = \begin{pmatrix} f_t^G \\ f_t^N \\ f_t^R \end{pmatrix} \quad (15)$$

O fator global é estimado considerando todas as variáveis explicativas. Já os fatores nominal e real são estimados considerando apenas, respectivamente, as variáveis classificadas em nominais e reais. O parâmetro μ é um vetor de dimensão N de constantes.

Banbura et al. (2011) utilizam uma especificação diferente para o DFM que não é na forma exata, permitindo autocorrelação serial nos componentes idiossincráticos, no qual cada um segue isoladamente um $AR(1)$:

$$\varepsilon_{i,t} = \alpha_i \varepsilon_{i,t-1} + e_{i,t}, \quad e_{i,t} \sim i.i.d. N(0, \sigma_i^2) \quad (16)$$

com $E[e_{i,t}e_{j,s}] = 0$ para $i \neq j$.

Uma outra novidade no modelo é que o vetor de séries x_t é composto por variáveis mensais e por uma medida mensal não observada do PIB. O que torna obsoleta a necessidade da equação (11) uma vez que séries de diferentes frequências são incorporadas conjuntamente no processo gerador.

Neste modelo os parâmetros, os fatores comuns e o PIB mensal não são observados, porém todos são estimados conjuntamente utilizando o *Expected Maximization algorithm*. Esse algoritmo utiliza a seguinte estrutura recursiva:

- E-step: A esperança da função de verossimilhança condicional é calculada utilizando as estimativas dos parâmetros estáticos (θ) da iteração anterior, θ_j ;
- M-step: Os novos parâmetros, θ_{j+1} são estimados pela maximização da função de verossimilhança do passo anterior, com respeito a θ .

O algoritmo então converge até que os parâmetros sejam iguais nas iterações. O processo recursivo se inicia com as estimativas de PCA apresentadas em Giannone et al. (2008) (primeiro estágio do método *Two Stages*).

2.4 Base de dados

Tabela 1: Data base.

Series code	Series name	Transformation	Delay
serie1	Exchange rate- Free- United States dollar (sale)-1 u.m.c/US\$	1	0
serie12	Interest rate- CDI	1	0
serie188	National Consumer Price Index (INPC)	4	14
serie189	General Price Index-Market (IGP-M)	0	0
serie192	National Index of Building Costs (INCC)	4	0
serie193	Consumer Price Index- Sao Paulo (IPC-FIPE)	4	7
serie194	Cost of Living Index (ICV-Dieese)	4	7
serie206	Staple food basket u.m.c	1	7
serie225	Wholesale Price Index (IPA)	0	14
serie432	Interest rate- Selic target	1	0
serie433	Broad National Consumer Price Index (IPCA)	4	7
serie1178	Interest rate- Selic in annual terms (basis 252)	4	0
serie1344	Installed capacity utilization- General(FGV)	3	0
serie1373	Vehicle production (total)	3	14
serie1374	Passenger cars and light commercial vehicles production	3	14
serie1375	Truck production	3	14
serie1376	Bus production	3	14
serie1377	Motorcycle production	3	14
serie1378	Vehicle sales (total)	3	14
serie1379	Domestic vehicle sales	3	14
serie1380	Vehicle exports	3	14
serie1382	Productions of mechanised cultivators	4	14
serie1383	Four wheel tractor production	3	14
serie1384	Track driven tractor production	3	14
serie1385	Production of combined harvesters	3	14
serie1386	Production of mechanical diggers	3	14
Continued on next page			

Tabela 1 – continued from previous page

Series code	Series name	Transformation	Delay
serie1387	Other agricultural machinery	3	14
serie1388	Production of agricultural machinery (total)	3	14
serie1389	Petroleum derivatives production- crude oil	1	42
serie1390	Petroleum derivatives production- LGN	1	42
serie1391	Petroleum derivatives production- total	1	42
serie1392	Petroleum derivatives production- natural gas	1	42
serie1402	Electric energy consumption- Brazil- commercial	3	42
serie1403	Electric energy consumption- Brazil- residential	3	42
serie1404	Electric energy consumption- Brazil- industrial	3	42
serie1405	Electric energy consumption- Brazil- other	3	42
serie1406	Electric energy consumption- Brazil- total	3	42
serie1453	Credit sales Index	3	21
serie1454	Cash Sales Index	3	21
serie1455	Sales volume index in the retail sector- Total- Brazil	3	70
serie1483	Sales volume index in the retail sector- Fuel and lubricants- Brazil	3	70
serie1496	Sales volume index in the retail sector- Hypermarkets, supermarket, food, beverages and tobacco- Brazil	3	70
serie1522	Sales volume index in the retail sector- Furniture and white goods- Brazil	3	70
serie1509	Sales volume index in the retail sector- Textiles, Clothing and Footwear- Brazil	3	70
serie1548	Sales volume index in the retail sector- Vehicles and motorcycles, spare parts- Brazil	3	70
serie1561	Sales volume index in the retail sector- Hypermarkets, supermarket- Brazil	3	70
serie2053	Net public debt- Balances in c.m.u. (million) - Total- Federal Government and Banco Central	1	35
serie2057	Net public debt- Balances in c.m.u. (million) - Total- State governments	1	35
serie2058	Net public debt- Balances in c.m.u. (million) - Total- Municipal governments	1	35
serie4393	Consumer confidence index	3	14
serie4394	Current economic conditions index	3	14
serie4395	Future expectations index	1	14
Continued on next page			

Tabela 1 – continued from previous page

Series code	Series name	Transformation	Delay
serie4503	Net public debt (%GDP)- total- Federal Government and Banco Central	2	35
serie4506	Net public debt (% GDP)- Total- State and municipal governments	2	35
serie4507	Net public debt (%GDP)- total- State governments	2	35
serie4508	Net public debt (% GDP)- total- Municipal governments	2	35
serie4509	Net public debt (%GDP)- total- State enterprises	2	35
serie4513	Net public debt(%GDP)- total- consolidated public sector	2	35
serie7341	Business confidence index- General	1	0
serie7357	Steel production (1992= 100)	3	42
serie7384	Sales of factory authorized vehicle outlets- Passenger cars sales	3	7
serie7385	Sales of factory authorized vehicle outlets- Light commercial cars sales	3	7
serie7386	Sales of factory authorized vehicle outlets- Truck sales	3	7
serie7412	Balanced checks - in 1000	3	98
serie7413	Returned checks - in 1000	3	98
serie7415	BNDES system disbursements- Total	3	21
serie7416	BNDES system disbursements- Manufacturing industry	3	21
serie7417	BNDES system disbursements- Commerce and Services	3	21
serie7418	BNDES system disbursements- Agricultural sector	3	21
serie7419	BNDES system disbursements- Vegetable extraction	3	21
serie7478	National consumer Price Index- Extended 15 (IPCA-15)	0	0
serie7495	SINAPI	0	14
serie7832	Ibovespa- monthly percent change	0	14
serie13667	Percent of 90 days past due loans of financial institutions under public control - Total	1	14
serie13673	Percent of 90 days past due loans of financial institutions under national private control - Total	1	14
serie13679	Percent of 90 days past due loans of financial institutions under foreign control - Total	1	14
serie13685	Percent of 90 days past due loans of financial institutions under private control - Total	1	14
serie20048	Commodity Index - Brazil (until Nov/2017)	1	14
Continued on next page			

Tabela 1 – continued from previous page

Series code	Series name	Transformation	Delay
serie20050	Commodity Index - Brazil Agriculture (until Nov/2017)	1	14
serie20051	Commodity Index - Brazil metal (until Nov/2017)	1	14
serie20052	Commodity Index - Brazil Energy (until Nov/2017)	1	14
serie20099	Pharmac., medical, orthop, and perfumery articles	3	70
serie20101	Books, newspaper, megazines	3	70
serie20102	Office, comp./ comunic, equip	3	70
serie20104	Other art. Of personal use	3	70
serie20105	Building materials	3	70
serie20106	Broad trade sector	3	70
serie20339	Sondagem de serviços - Índice de Confiança de Serviços- Dessazonalizado	1	7
serie20340	Sondagem de Serviços - Índice de Expectativas (IE-S) - Dessazonalizado	1	7
serie20341	Residential Real Estate Collateral Value Index	1	98
serie21637	PMS- Nominal revenue from services - Total - Brazil	3	42
serie21859	General (2012=100)	3	35
serie21861	Physical Production- Mineral extraction	3	35
serie21862	Physical Production - Manufacturing Industry	3	35
serie21863	Physical Production - Capital goods	3	35
serie21864	Physical Production- Intermediate goods	3	35
serie21865	Physical Production - Consumer goods	3	35
serie21866	Physical Production - Durable goods	3	35
serie21867	Physical Production - Semi durable and nondurable goods	3	35
serie21868	Physical Production - Production of construction inputs	3	35
serie21924	Industrial Production (2012=100)- Southeast Region	3	35
serie21930	Industrial Production (2012=100)- Northern Region	3	35
serie21934	Industrial Production (2012=100)- South	3	35
serie21939	Industrial Production (2012=100)- Central- Western Region	3	35
Continued on next page			

Tabela 1 – continued from previous page

Series code	Series name	Transformation	Delay
serie21961	Industrial Production (2012=100)- Northeast	3	35
serie22099	Quarterly GDP- observed data- GDP at market prices	3	70
serie22109	Quarterly GDP - seasonally adjusted data - GDP at market prices	1	70
serie22704	Balance on goods and services - monthly - net	3	21
serie22705	Balance on goods and services - monthly - credit	3	21
serie22706	Balance on goods and services - monthly - debit	3	21
serie22707	Balance on goods- Balance of Payments - monthly- net	3	21
serie24352	Capacity utilization- manufacturing industry (FGV)	1	21
serie24369	Enemployment - PNAD	3	28
serie24370	Working age populaton - Continuous PNAD	1	28
serie24378	Labor force population - Continuous PNAD	1	28
serie24379	Employed population - Continuous PNAD	3	28
serie24382	Real habitually average earnings of employed people- Continuous PNAD	1	28
serie25241	Registered employees Index - Manufacturing	3	28
ICI	ICI with seasonal adjust - Industry confidence index	1	0
ISA	ISA with seasonal adjust - Industry confidence index - Actual situation	1	0
IE	IE with seasonal adjust - Industry confidence index - Expectation	1	0
ICOM	ICOM with seasonal adjust-Retail sector extended index	1	0
ISACOM	ISA-COM with seasonal adjust-Retail sector extended actual situtation index	1	0
IECOM	IE-COM with seasonal adjust-Retail sector extended expected index	1	0
ICS	ICS with seasonal adjust - Service confidence index	1	0
ISAS	ISA-S with seasonal adjust - Service confidence index- Actual situation	1	0
IES	IE-S with seasonal adjust - Service confidence index- Expectation	1	0

3 Nowcasting do PIB brasileiro

apresentar a ordem de cada modelo e quais variáveis
análise pseudo fora da amostra para avaliar a previsão do PIB
avaliar como a divulgação das variáveis impactam na previsão do PIB
previsão do PIB 2018
mostrar link do shiny com a atualização da previsão atual, realtime

4 Considerações finais

concluir o trabalho e apresentar trabalhos futuros

Referências

- Banbura, M., Giannone, D., & Reichlin, L. (2011). Nowcasting. *Oxford Handbook on Economic Forecasting*.
- Bañbura, M., & Rünstler, G. (2011). A look into the factor model black box: publication lags and the role of hard and soft data in forecasting gdp. *International Journal of Forecasting*, 27(2), 333–346.
- Giannone, D., Reichlin, L., & Small, D. (2008). Nowcasting: The real-time informational content of macroeconomic data. *Journal of Monetary Economics*, 55(4), 665–676.
- Mariano, R. S., & Murasawa, Y. (2003). A new coincident index of business cycles based on monthly and quarterly series. *Journal of applied Econometrics*, 18(4), 427–443.
- Stock, J. H., & Watson, M. (2011). Dynamic factor models. *Oxford Handbook on Economic Forecasting*.
- Stock, J. H., & Watson, M. W. (2006). Forecasting with many predictors. *Handbook of economic forecasting*, 1, 515–554.